

Sistemas de recomendação de filmes

Comparação de SVD e KNN no MovieLens 100k

Arthur Gon RA 811464

Laboratório de Estatística Aplicada 2026/2

Docente: Victor Coscrato

Este trabalho compara SVD e KNN de usuários no MovieLens 100k, conforme a atividade proposta em aula [1]. A análise distingue o erro de predição das notas da capacidade de recuperar filmes relevantes em uma lista de dez. Além dos resultados médios, examina a consistência entre partições, o suporte das recomendações e a distribuição do ganho entre usuários.

1. Dados e análise exploratória

O MovieLens 100k [2] reúne 100.000 notas de 1 a 5, atribuídas por 943 usuários a 1.682 filmes. Os arquivos originais foram preservados: não há notas ausentes nos registros, valores fora de [1, 5] ou pares usuário–filme duplicados. Não houve exclusão nem imputação; posições sem avaliação permanecem ausentes.

A média é 3,53 e 55,4% das avaliações são 4 ou 5. As distribuições de atividade, porém, são bastante assimétricas (Figura 1).




Figura 1: Distribuição das notas e da quantidade de avaliações por usuário e por filme. As caudas à direita mostram a concentração da atividade.

Tabela 1: Quantidade de avaliações. A distância entre média e mediana destaca a assimetria observada nos histogramas.

Unidade	Média	Mínimo	Mediana	3º quartil	Máximo
Usuário	106,0	20	65	148	737
Filme	59,5	1	27	80	583

A matriz tem 93,70% de posições sem nota, e metade das avaliações se concentra em 12,78% do catálogo. No outro extremo, 384 filmes têm até cinco avaliações, dos quais 141 têm apenas uma. Assim, notas médias extremas podem ter pouco suporte, e nem sempre há muitos filmes em comum para comparar dois usuários.

Os dados descrevem avaliações observadas, não o gosto por todos os filmes não avaliados. A coleta ocorreu em 1997–1998; 71,0% dos usuários cadastrados são homens e a mediana de idade é 31 anos. Os dados demográficos não entram no treinamento.

2. Como a comparação foi feita

2.1 Validação e métricas

São usados os cinco particionamentos oficiais (u1 a u5), com 80.000 notas de treino e 20.000 de teste. Cada treino é dividido aleatoriamente em 64.000 notas para ajuste e 16.000 para escolha dos hiperparâmetros, com semente $42 + f$ na partição f . A configuração escolhida é reajustada nas 80.000 notas. O teste externo não orienta a seleção; os cinco testes são disjuntos e cobrem as 100.000 avaliações.

O **RMSE** mede o erro sobre todas as notas de teste, com previsões limitadas a $[1, 5]$. A **Precisão@10** mede a proporção de acertos na lista:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum (r_{ui} - \hat{r}_{ui})^2}, \quad \text{P@10}(u) = \frac{|L_u \cap T_u^+|}{10}.$$

L_u contém os dez recomendados e T_u^+ , os filmes com nota de teste ≥ 4 . São candidatos todos os filmes não avaliados pelo usuário no treino, sem amostrar negativos. A precisão é a média entre usuários com ao menos um relevante no teste (456 a 890 por partição). Empates são resolvidos pelo id do filme. MAE e nDCG@10 complementam a comparação; o nDCG usa ganho binário para notas 4 e 5, desconto pela posição e normalização pela ordem ideal.

2.2 Modelos e escolha das configurações

O **SVD** (FunkSVD) estima $\hat{r}_{ui} = \mu + b_u + b_i + p_u^\top q_i$, com média do treino μ , vieses b e fatores p, q ajustados por SGD regularizado. O **KNN** usa cosseno sobre notas centradas na média de cada usuário. Médias e similaridades usam apenas o treino. No cosseno, ausências viram zero após a centralização; as normas são das linhas completas. Entre os k vizinhos mais similares, somente os que avaliaram o filme contribuem:

$$\hat{r}_{ui} = \mu_u + \frac{\sum_{v \in N_k(u,i)} s_{uv} (r_{vi} - \mu_v)}{\sum_{v \in N_k(u,i)} s_{uv}}.$$

São mantidas similaridades positivas, com peso opcional $\min(n_{uv}, h)/h$ pelo número de filmes em comum; $h = 0$ desativa esse peso. Sem suporte, usa-se μ_u . A comparação principal ordena pelas notas previstas. A variante **KNN por soma** ordena apenas pelo numerador, retendo a contribuição acumulada dos mesmos vizinhos; o erro de nota não muda. SVD e KNN por nota são ordenados antes do recorte em $[1, 5]$.

Tabela 2: Busca interna e escolhas. SVD e KNN minimizam RMSE; o suporte da nota média maximiza $P@10$. d : fatores; η : taxa de aprendizagem; λ : regularização.

Modelo	Configurações testadas	Selecionado
KNN	k : 10, 20, 40, 80, 160, 300; h : 0 ou 50	$k = 300$; $h = 50$ em u1, u4, u5 e 0 em u2, u3
SVD	d : 20, 50, 100; η : 0,005 ou 0,01; λ : 0,05 ou 0,10	$d = 50$ em u1 e 100 nos demais; $\eta = 0,01$, $\lambda = 0,10$
Nota média	Suporte: 1, 5, 10, 20, 40, 80, 150	150 nas cinco partições

As referências ordenam por sorteio, quantidade de avaliações ou nota média com suporte mínimo. Para prever notas, popularidade usa a média do filme com dez notas equivalentes à média global; nota média usa a média global nos itens excluídos. A média global prevê uma constante. O sorteio usa notas contínuas uniformes em $[1, 5]$. O SVD usa 40 épocas seriais e semente 42. Filmes sem treino têm fatores e vieses nulos no SVD; permanecem os termos estimáveis.

3. Resultados e comparações

Tabela 3: Média das cinco partições externas, com pesos iguais. DP é o desvio-padrão entre partições, não um intervalo de confiança. Menores erros e maiores precisões são melhores. As duas ordenações do KNN compartilham as previsões de nota.

Modelo	RMSE $\pm$ DP	MAE	P@10 $\pm$ DP	nDCG@10
Aleatório	1,6999 $\pm$ 0,0186	1,3902	0,0105 $\pm$ 0,0027	0,0113
Mais populares	1,0256 $\pm$ 0,0113	0,8203	0,1568 $\pm$ 0,0372	0,1982
Melhores avaliados	1,0937 $\pm$ 0,0155	0,8933	0,1179 $\pm$ 0,0286	0,1273
KNN por nota	0,9411 $\pm$ 0,0063	0,7346	0,0007 $\pm$ 0,0006	0,0007
KNN por soma	0,9411 $\pm$ 0,0063	0,7346	0,2014 $\pm$ 0,0466	0,2629
SVD	0,9098 $\pm$ 0,0069	0,7182	0,0753 $\pm$ 0,0241	0,0786
Média global	1,1256 $\pm$ 0,0174	0,9447	–	–

O **SVD é o melhor estimador de notas**: reduz o RMSE em 3,3% em relação ao KNN e o supera nas cinco partições. Também produz listas melhores que o KNN ordenado por nota prevista. A variante por soma inverte o resultado do ranking: alcança 0,2014 de precisão, equivalente a 2,01 acertos por lista, contra 0,75 do SVD e 1,57 da popularidade.




Figura 2: (a) Posição dos modelos nos dois objetivos: o canto superior esquerdo combina menor erro com mais acertos. (b) Ganhos de acertos por lista, sempre comparando métodos na mesma partição. Cada círculo representa uma das cinco partições; o losango é a média e o segmento mostra a amplitude, sem inferência estatística. Valores positivos favorecem o primeiro método.

A vantagem sobre um modelo simples é menor que a vantagem sobre o SVD. O KNN por soma acrescenta 1,26 acerto por lista em relação ao SVD, mas 0,45 em relação à popularidade, um ganho relativo de 28,4%. Essa segunda comparação dimensiona o benefício além de simplesmente recomendar filmes muito avaliados. Os ganhos são positivos nas cinco partições.

O resultado aleatório fica próximo da expectativa exata 0,0103, calculada pela fração de filmes relevantes entre candidatos, nos mesmos usuários da comparação.

Com os mesmos vizinhos, a regra de ordenação muda radicalmente a precisão. O diagnóstico seguinte examina essa diferença sem alterar as configurações.

4. O que as médias escondem




Figura 3: (a) Vizinhos que avaliaram cada recomendado: média por lista, uma linha por partição. (b) RMSE por suporte no treino: pontos são médias entre partições; segmentos, mínimos e máximos.

O KNN por nota apoia cada recomendação em 1,6 vizinhos, em média, contra 117,0 na soma. Os filmes escolhidos têm, respectivamente, 4,8 e 274,3 avaliações no treino. A normalização permite notas altas com poucos vizinhos; a soma retém o volume de evidência. O contraste sugere fragilidade com pouco suporte, mas não separa esse efeito da preferência por filmes populares.

O SVD tem menor RMSE em todas as faixas de suporte e nas cinco partições (Figura 3b). Porém, apenas 1.636 notas de teste envolvem filmes com até cinco avaliações no treino, contra 55.907 com mais de 100: o erro agregado representa sobretudo filmes com mais histórico.




Figura 4: KNN por soma versus popularidade: usuários com menos, iguais ou mais acertos por lista em cada teste externo.

O ganho médio não beneficia todos. Em média entre partições, 38,7% ganham acertos, 39,1% empatam e 22,2% perdem. Os mesmos usuários podem reaparecer em diferentes partições.

5. Conclusão

Neste protocolo, SVD é mais adequado para prever notas; KNN por soma, para listas de dez. Este supera a popularidade nas cinco partições, mas não para todos os usuários.

Os resultados se limitam às avaliações observadas, em dados antigos e sem divisão temporal. Ausência de nota não implica desinteresse; as diferenças entre partições com treinos sobrepostos são descritivas.

Referências

- [1] COSCRATO, V. *Sistemas de recomendação*. LEA, 2026/2. <https://teaching.vcoscrato.com/sisrec/>. Acesso: 8 out. 2026.
- [2] HARPER, F. M.; KONSTAN, J. A. The MovieLens Datasets: History and Context. *ACM TiiS*, 5(4), 19, 2015. DOI: 10.1145/2827872. Dados: <https://grouplens.org/datasets/movielens/100k/>.

Reprodutibilidade: código, resultados e instruções

<https://github.com/ArthurGoon/lea-sistemas-de-recomendacao>